

26-1 데이터관리와 분석

Project 1

Conceptual DB Design & Implementation

INDEX

목차



목차1

Part1 - 문제 정의, 주요 설계, 주요 제약조건, ERD



목차2

Part 2 - 문제 정의, 중복 데이터 미삽입 건, 설계 스키마 및 코드



목차3


결론





01

Part 1



문제 정의

서비스 A는 온라인 Q&A 커뮤니티. 사용자는 질문·답변·댓글·투표를 생성하고, 게시물에 태그가 부여되며, 우수 활동 사용자에게 배지가 수여됨. 수정 이력이 기록되며 게시물 간 연결 관계가 존재함. → ER diagram

핵심 목표 및 방법론

1



Requirements 분석

10개 요구사항으로부터
Entity / Attribute / Relationship
식별

2



설계 결정

수정 및 보완 과정
(Attribute → Relationship 전환
등)

3



Constraints 확정

Cardinality ratio &
Participation constraints 결정
• (min, max) notation 미사용



주요 설계 결정 사항

✓ R1-2/3/4 Posts ↔ Question / Answer

상호 배타적(disjoint) 제약 : 하나의 Post는 Question 또는 Answer 중 하나에만 속함
EER specialization 미사용 - 1:1 relationship으로 표현, 텍스트 제약조건 명시

✓ R1-10 Postlinks - Entity → Relationship 변경

초기 설계: PostLinks를 Entity로 - 그러나 두 게시물 간 연결 관계를 나타내므로 Relationship이 적합하다고 판단
최종: Posts 간 M:N recursive relationship(POST_LINKS)로 변경

✓ R1-7 Tags - ExcerptPostId / WikiPostId

데이터 확인 결과 Tags 테이블에 ExcerptPostId, WikiPostId 존재
Tags → Post 간 1:1 relationship 추가(HAS_EXCERPT, HAS_WIKI)

ER Diagram의 제약조건

배경

R1-2에 따라 게시물(Post)은 질문 또는 답변 중 하나에만 속해야 하는 상호 배타적(Disjoint) 제약이 존재
EER의 specialization 기호를 사용할 수 없어, ER diagram 상에 텍스트로 제약조건을 직접 명시



명시한 Constraint

어떤 Posts도 Question과 Answer에 동시에 속할 수 없다.



Relationship : IS_QUESTION




Posts (partial) → Question (total)
Cardinality: 1:1
모든 Question은 Posts에 대응되지만,
Posts가 반드시 Question일 필요는 없음

Relationship 2 : IS_ANSWER



Posts (partial) → Answer (total)
Cardinality: 1:1
모든 Answer는 Posts에 대응되지만,
Posts가 반드시 Answer일 필요는 없음

최종 ER Diagram




9 Entities

16 Relationships



02


Part 2



문제 정의

목표: PART I의 ER diagram을 바탕으로 MySQL 관계형 스키마를 설계하고, Python(v3.14.3.)으로 데이터 입력. ER diagram에서 표현되지 않은 FK constraint, NULL 허용 여부, M:N → 중간 테이블 변환 등 결정

핵심 목표 및 방법론





중복 데이터 미삽입 (R2-3)

발견된 문제

comments.csv 데이터 검토 결과 동일 PostId + 동일 Id를 가지는 튜플이 존재함을 확인
Comments는 Weak Entity로 설계되어 (Id, PostId) 복합키 제약이 적용되는데, 이는 R1-5의 '게시물 내 댓글 순번'이라는 해석과는 부합하지 않는 데이터 이상인 것으로 판단

처리 결정

데이터를 임의로 수정하지 않고 중복 행을 삽입하지 않는 방식 선택
(R2-3 요구사항: csv 파일을 직접 변형하지 않을 것)

삽입 결과

테이블	csv 원본 건수	삽입된 건수	차이
comments	171,467	169,740	▼ 1,727

다른 테이블

테이블	csv 원본 건수	삽입된 건수
users	40,325	40,325
posts	91,977	91,977
question	42,921	42,921
answer	47,756	47,756
votes	323,233	323,233
tags	1,032	1,032
badges	79,851	79,851
postHistory	275,281	275,279
postLinks	11,102	11,102



File Edit View Query Database Server Tools Scripting Help

am15.answer answer - Table dma_team15.votes votes - Table votes users

Limit to 1000 rows

1 • `SELECT * FROM dma_team15.users;`

Result Grid

	UserId	Reputation	DisplayName	Age	CreationDate	LastAccessDate	WebsiteUrl
▶	0	0	0	NULL	2013-11-07 11:35:00	2013-11-07 11:35:00	NULL
	2	101	Geoff Dalgas	37	2010-07-19 14:01:00	2013-11-12 22:07:00	http://sta
	3	101	Jarrod Dixon	35	2010-07-19 15:34:00	2014-08-08 06:42:00	http://sta
	4	101	Emmett	28	2010-07-19 19:03:00	2014-01-02 09:31:00	http://min
	5	6792	Shane	35	2010-07-19 19:03:00	2014-08-13 00:23:00	http://ww
	6	457	Harlan	41	2010-07-19 19:04:00	2014-08-07 19:49:00	http://ww
	7	429	Vince	28	2010-07-19 19:04:00	2014-09-10 21:14:00	http://bioi
	8	6764	csgillespie	36	2010-07-19 19:04:00	2014-09-09 21:15:00	http://ww
	10	121	Pierre	44	2010-07-19 19:05:00	2014-07-28 18:15:00	http://plin
	11	136	wahalulu	40	2010-07-19 19:06:00	2014-07-23 21:28:00	http://ww
	12	101	Jin	38	2010-07-19 19:06:00	2014-09-09 20:26:00	http://ww
	13	817	Sharpie	28	2010-07-19 19:06:00	2014-08-14 17:28:00	http://ww
	15	11	hannes.koller	35	2010-07-19 19:07:00	2010-08-24 14:23:00	http://son
	16	101	elachnick	31	2010-07-19 19:08:00	2010-08-10 20:40:00	NULL

Form Editor Field Types Query Stats

Automatic context help is disabled. Use the toolbar to manually get help for the current caret position or to toggle automatic help.

Table: **users**

Columns:

UserId	int PK
Reputation	int
DisplayName	varchar(255)
Age	int
CreationDate	datetime
LastAccessDate	datetime
WebsiteUrl	varchar(255)
Location	varchar(255)
AboutMe	longtext

Object Info Session

users 1 x Apply Revert Context Help Snippets

Output

Action Output

#	Time	Action	Message	Duration / Fetch
✓ 1	14:51:44	SELECT * FROM dma_team15.votes LIMIT 0, 1000	1000 row(s) returned	0.032 sec / 0.000 sec
✓ 2	14:51:50	SELECT * FROM dma_team15.users LIMIT 0, 1000	1000 row(s) returned	0.015 sec / 0.000 sec



```
# Requirement2: create table
def requirement2(host, user, password):
    cnx = mysql.connector.connect(host=host, user=user, password=password, database='DMA_team15')
    cursor = cnx.cursor()
    try:
        cursor.execute('SET GLOBAL innodb_buffer_pool_size=2*1024*1024*1024;')
    except mysql.connector.Error:
        pass
    print('Creating tables...')

    # users
    cursor.execute('''
        CREATE TABLE IF NOT EXISTS users (
            UserId INT(11) NOT NULL,
            Reputation INT(11) NOT NULL,
            DisplayName VARCHAR(255) NOT NULL,
            Age INT(11),
            CreationDate DATETIME NOT NULL,
            LastAccessDate DATETIME NOT NULL,
            WebsiteUrl VARCHAR(255),
            Location VARCHAR(255),
            AboutMe LONGTEXT,
            PRIMARY KEY (UserId)
        )
    ''')
```



```
def requirement3(host, user, password, directory):  
    def flush(cursor, cnx, sql, batch):  
        if batch:  
            try:  
                cursor.executemany(sql, batch)  
            except mysql.connector.Error:  
                cnx.rollback()  
  
            for row in batch:  
                try:  
                    cursor.execute(sql, row)  
                except mysql.connector.Error:  
                    pass  
            cnx.commit()  
  
    def read_csv(filepath):  
        return csv.reader(open(filepath, 'r', encoding='utf-8', errors='replace'))  
  
    # --- users (40,325 rows) ---  
    print(' Inserting users...')  
    reader = read_csv(directory + 'users.csv')  
    next(reader)  
    batch = []  
    for row in reader:  
        batch.append(  
            int(row[0]),           # UserId  
            int(row[1]),           # Reputation  
            row[2],                 # DisplayName  
            to_int(row[3]),         # Age  
            convert_dot_date(row[4]), # CreationDate  
            convert_dot_date(row[5]), # LastAccessDate  
            to_str(row[6]),         # WebsiteUrl  
            to_str(row[7]),         # Location  
            to_str(row[8]) if len(row) > 8 else None, # AboutMe, 마지막 column 없을 경우 방어  
        )  
        if len(batch) >= BATCH_SIZE:  
            flush(cursor, cnx, 'INSERT INTO users VALUES (%s,%s,%s,%s,%s,%s,%s,%s,%s)', batch)
```




```
# Requirement4: add constraint (foreign key)
def requirement4(host, user, password):
    cnx = mysql.connector.connect(host=host, user=user, password=password, database='DMA_team15')
    cursor = cnx.cursor()
    try:
        cursor.execute('SET GLOBAL innodb_buffer_pool_size=2*1024*1024*1024;')
    except mysql.connector.Error:
        pass
    print('Adding constraints...')

    fk_queries = [
        'ALTER TABLE posts ADD FOREIGN KEY (OwnerUserId) REFERENCES users(UserId)',
        'ALTER TABLE question ADD FOREIGN KEY (PostId) REFERENCES posts(Id)',
        'ALTER TABLE question ADD FOREIGN KEY (AcceptedAnswerId) REFERENCES answer(Id)',
        'ALTER TABLE answer ADD FOREIGN KEY (PostId) REFERENCES posts(Id)',
        'ALTER TABLE answer ADD FOREIGN KEY (ParentId) REFERENCES question(Id)',
        'ALTER TABLE comments ADD FOREIGN KEY (PostId) REFERENCES posts(Id)',
        'ALTER TABLE comments ADD FOREIGN KEY (UserInfoId) REFERENCES users(UserId)',
        'ALTER TABLE votes ADD FOREIGN KEY (PostId) REFERENCES posts(Id)',
        'ALTER TABLE votes ADD FOREIGN KEY (UserInfoId) REFERENCES users(UserId)',
        'ALTER TABLE tags ADD FOREIGN KEY (ExcerptPostId) REFERENCES posts(Id)',
        'ALTER TABLE tags ADD FOREIGN KEY (WikiPostId) REFERENCES posts(Id)',
        'ALTER TABLE badges ADD FOREIGN KEY (UserInfoId) REFERENCES users(UserId)',
        'ALTER TABLE postHistory ADD FOREIGN KEY (PostId) REFERENCES posts(Id)',
        'ALTER TABLE postHistory ADD FOREIGN KEY (UserInfoId) REFERENCES users(UserId)',
        'ALTER TABLE postLinks ADD FOREIGN KEY (PostId) REFERENCES posts(Id)',
        'ALTER TABLE postLinks ADD FOREIGN KEY (RelatedPostId) REFERENCES posts(Id)',
    ]

    for query in fk_queries:
        cursor.execute(query)

    cnx.commit()
    cursor.close()
    cnx.close()
```


결론

1

9개 Entity, 16개 Relationship을 설계하여 10개 요구사항을 만족하는 ER diagram 도출

2

ER diagram을 관계형 스키마(MySQL)로 구현하고, 10개 테이블에 데이터 입력 완료

3

Posts-Question-Answer 간 상호 배타성은 ER diagram으로 완전히 표현하지 못해 텍스트 제약조건으로 보완

4

Comments 중복 데이터(1,727건) — 데이터 변형 없이 중복 행 미삽입으로 처리하여 일부 데이터 손실 발생



Thank You

감사합니다

DMA_Project1_Team 15